

Cours : Les Attaques Adversaires par Évasion

Cours : Les Attaques Adversaires par Evasion

I. Introduction aux Attaques Adversaires

Definition generale :

Une attaque adverse est une tentative de manipulation d'un modele de machine learning en injectant des perturbations specifiques dans les donnees d'entree.

Attaques par evasion :

Survienent au moment de l'inference (modele deja entraine). Le but est de modifier legerement une entree pour que le modele se trompe.

II. Fonctionnement des Attaques par Evasion

Principe :

Modifier l'entree x pour obtenir x' tel que $f(x) = f(x')$ tout en gardant $\|x - x'\| < \epsilon$.

Types de scenarios :

- Boite blanche : tout est connu.
- Boite noire : seul l'accès aux sorties.
- Boite grise : connaissances partielles.

III. Types d'Attaques par Evasion

1. FGSM :

Cours : Les Attaques Adversaires par Évasion

$$x' = x + \epsilon \cdot \text{sign}(\nabla_x J(x, y))$$

2. PGD :

Attaque itérative, plus forte que FGSM.

3. Carlini & Wagner :

Optimisation avec contrainte sur norme L2.

4. DeepFool :

Méthode géométrique vers la frontière de décision.

5. Black-box :

- ZOO : estimation des gradients.
- Boundary Attack : méthode sans gradients.

IV. Défenses Contre l'Évasion

1. Adversarial Training :

Entraînement sur des exemples adversaires.

2. Régularisation :

Distillation défensive, bruit gaussien.

3. Détection :

Détection statistique, auto-encodeurs.

Cours : Les Attaques Adversaires par Évasion

4. Randomisation :

Transformations aleatoires detruisant la perturbation.

5. Certification :

Preuves mathematiques de robustesse.

V. Cas d'Usage

- Reconnaissance faciale, voitures autonomes, biometrie.
- Exemple : Google Cloud Vision trompe par un panda modifie.

VI. Limites et Controverses

- Defenses contournables.
- Compromis robustesse / precision.
- Difficulte de mesure de robustesse.

VII. Ressources

- Librairies : Foolbox, CleverHans, ART.
- Articles cles : Goodfellow 2015, Madry 2018, Carlini & Wagner 2017.