

SUJET - LA SÉCURISATION DES SYSTÈMES D'APPRENTISSAGE AUTOMATIQUE

La sécurité en Apprentissage Automatique

Froehly Jean-Baptiste
20/06/2025



Sommaire

01 Introduction

02 Compréhension du sujet

03 Objectif des recherches et problématique

04 Enjeux et difficultés

05 Résultats et analyse

06 Analyse du stage

07 Conclusion

01 - Introduction

STRUCTURE D'ACCUEIL

IUT Belfort - Montbéliard

- 19 av. du Maréchal Juin, BELFORT, 90016



STRUCTURE D'ACCUEIL - CADRE

Femto ST - DISC



- DISC : Département d'informatique des systèmes complexes
- Département d'environ 100 personnes
- 4 équipes de recherches

Domaines d'expertise :

- Fiabilité, sûreté et sécurité dans les systèmes complexes
- Micro et nanosystèmes distribués intelligents
- Intelligence artificielle et calcul distribué
- E-Santé et bio-informatique

THÈMES

“Sécurisation Des Systèmes D'apprentissage Automatique : Analyse Des Menaces Et Mécanismes De Défense”




THÈMES

“Sécurisation Des Systèmes D'apprentissage Automatique : Analyse Des Menaces Et Mécanismes De Défense”




THÈMES

“Sécurisation Des Systèmes D'apprentissage Automatique : Analyse Des Menaces Et Mécanismes De Défense”



THÈMES

“Sécurisation Des Systèmes D'apprentissage Automatique : Analyse Des Menaces Et Mécanismes De Défense”



02 - Compréhension du sujet

“Sécurisation Des Systèmes D'apprentissage Automatique : Analyse Des Menaces Et Mécanismes De Défense”

L'APPRENTISSAGE AUTOMATIQUE (MACHINE LEARNING)

Qu'est-ce donc ?

- Un sous domaine de l'Intelligence Artificielle (IA)
- Développement d'algorithmes et modèles qui apprennent et s'améliorent à partir de données

Types :

- Apprentissage supervisé : données étiquetées pour entraîner les modèles
- Apprentissage non supervisé : utilisation de données non étiquetées
- Apprentissage par renforcement : apprentissage par essais et erreurs

L'APPRENTISSAGE AUTOMATIQUE (MACHINE LEARNING)


Qu'est-ce donc ?

- Un sous domaine de l'Intelligence Artificielle (IA)
- Développement d'algorithmes et modèles qui apprennent et s'améliorent à partir de données

Types :

- Apprentissage supervisé : données étiquetées pour entraîner les modèles ✓
- Apprentissage non supervisé : utilisation de données non étiquetées
- Apprentissage par renforcement : apprentissage par essais et erreurs

Qu'est-ce que l'apprentissage automatique (Machine Learning)



1

Données

Structurées ou non

2

Apprentissage au travers de l'algo


3

Prédiction


4

Evaluation de la prédiction

Retour à l'apprentissage en
rééquilibrant selon la
satisfaction




Qu'est-ce que l'apprentissage automatique (Machine Learning)



1


Données

Structurées ou non



Validation de la fonction

l'apprentissage en
tenant compte de la
validation




Qu'est-ce que l'apprentissage automatique (Machine Learning)

1

Données

Structurées ou non



ation de la ction

l'apprentissage en
rant selon la
tion

Sécurité de l'apprentissage automatique

Cible des attaques :

1

Données

2

Modèle

3

Infrastructure

4

Utilisateur

Sécurité de l'apprentissage automatique

Cible des attaques :




Sécurité de l'apprentissage automatique

Cible des attaques :



Vecteurs numériques




Vecteurs Matériels ou humains

Sécurité de l'apprentissage automatique

Cible des attaques :



Vecteurs numériques



Vecteurs Matériels ou humains




Sécurité de l'a

Cible des attaques :

1

Données

Vecteurs numér



Sujet

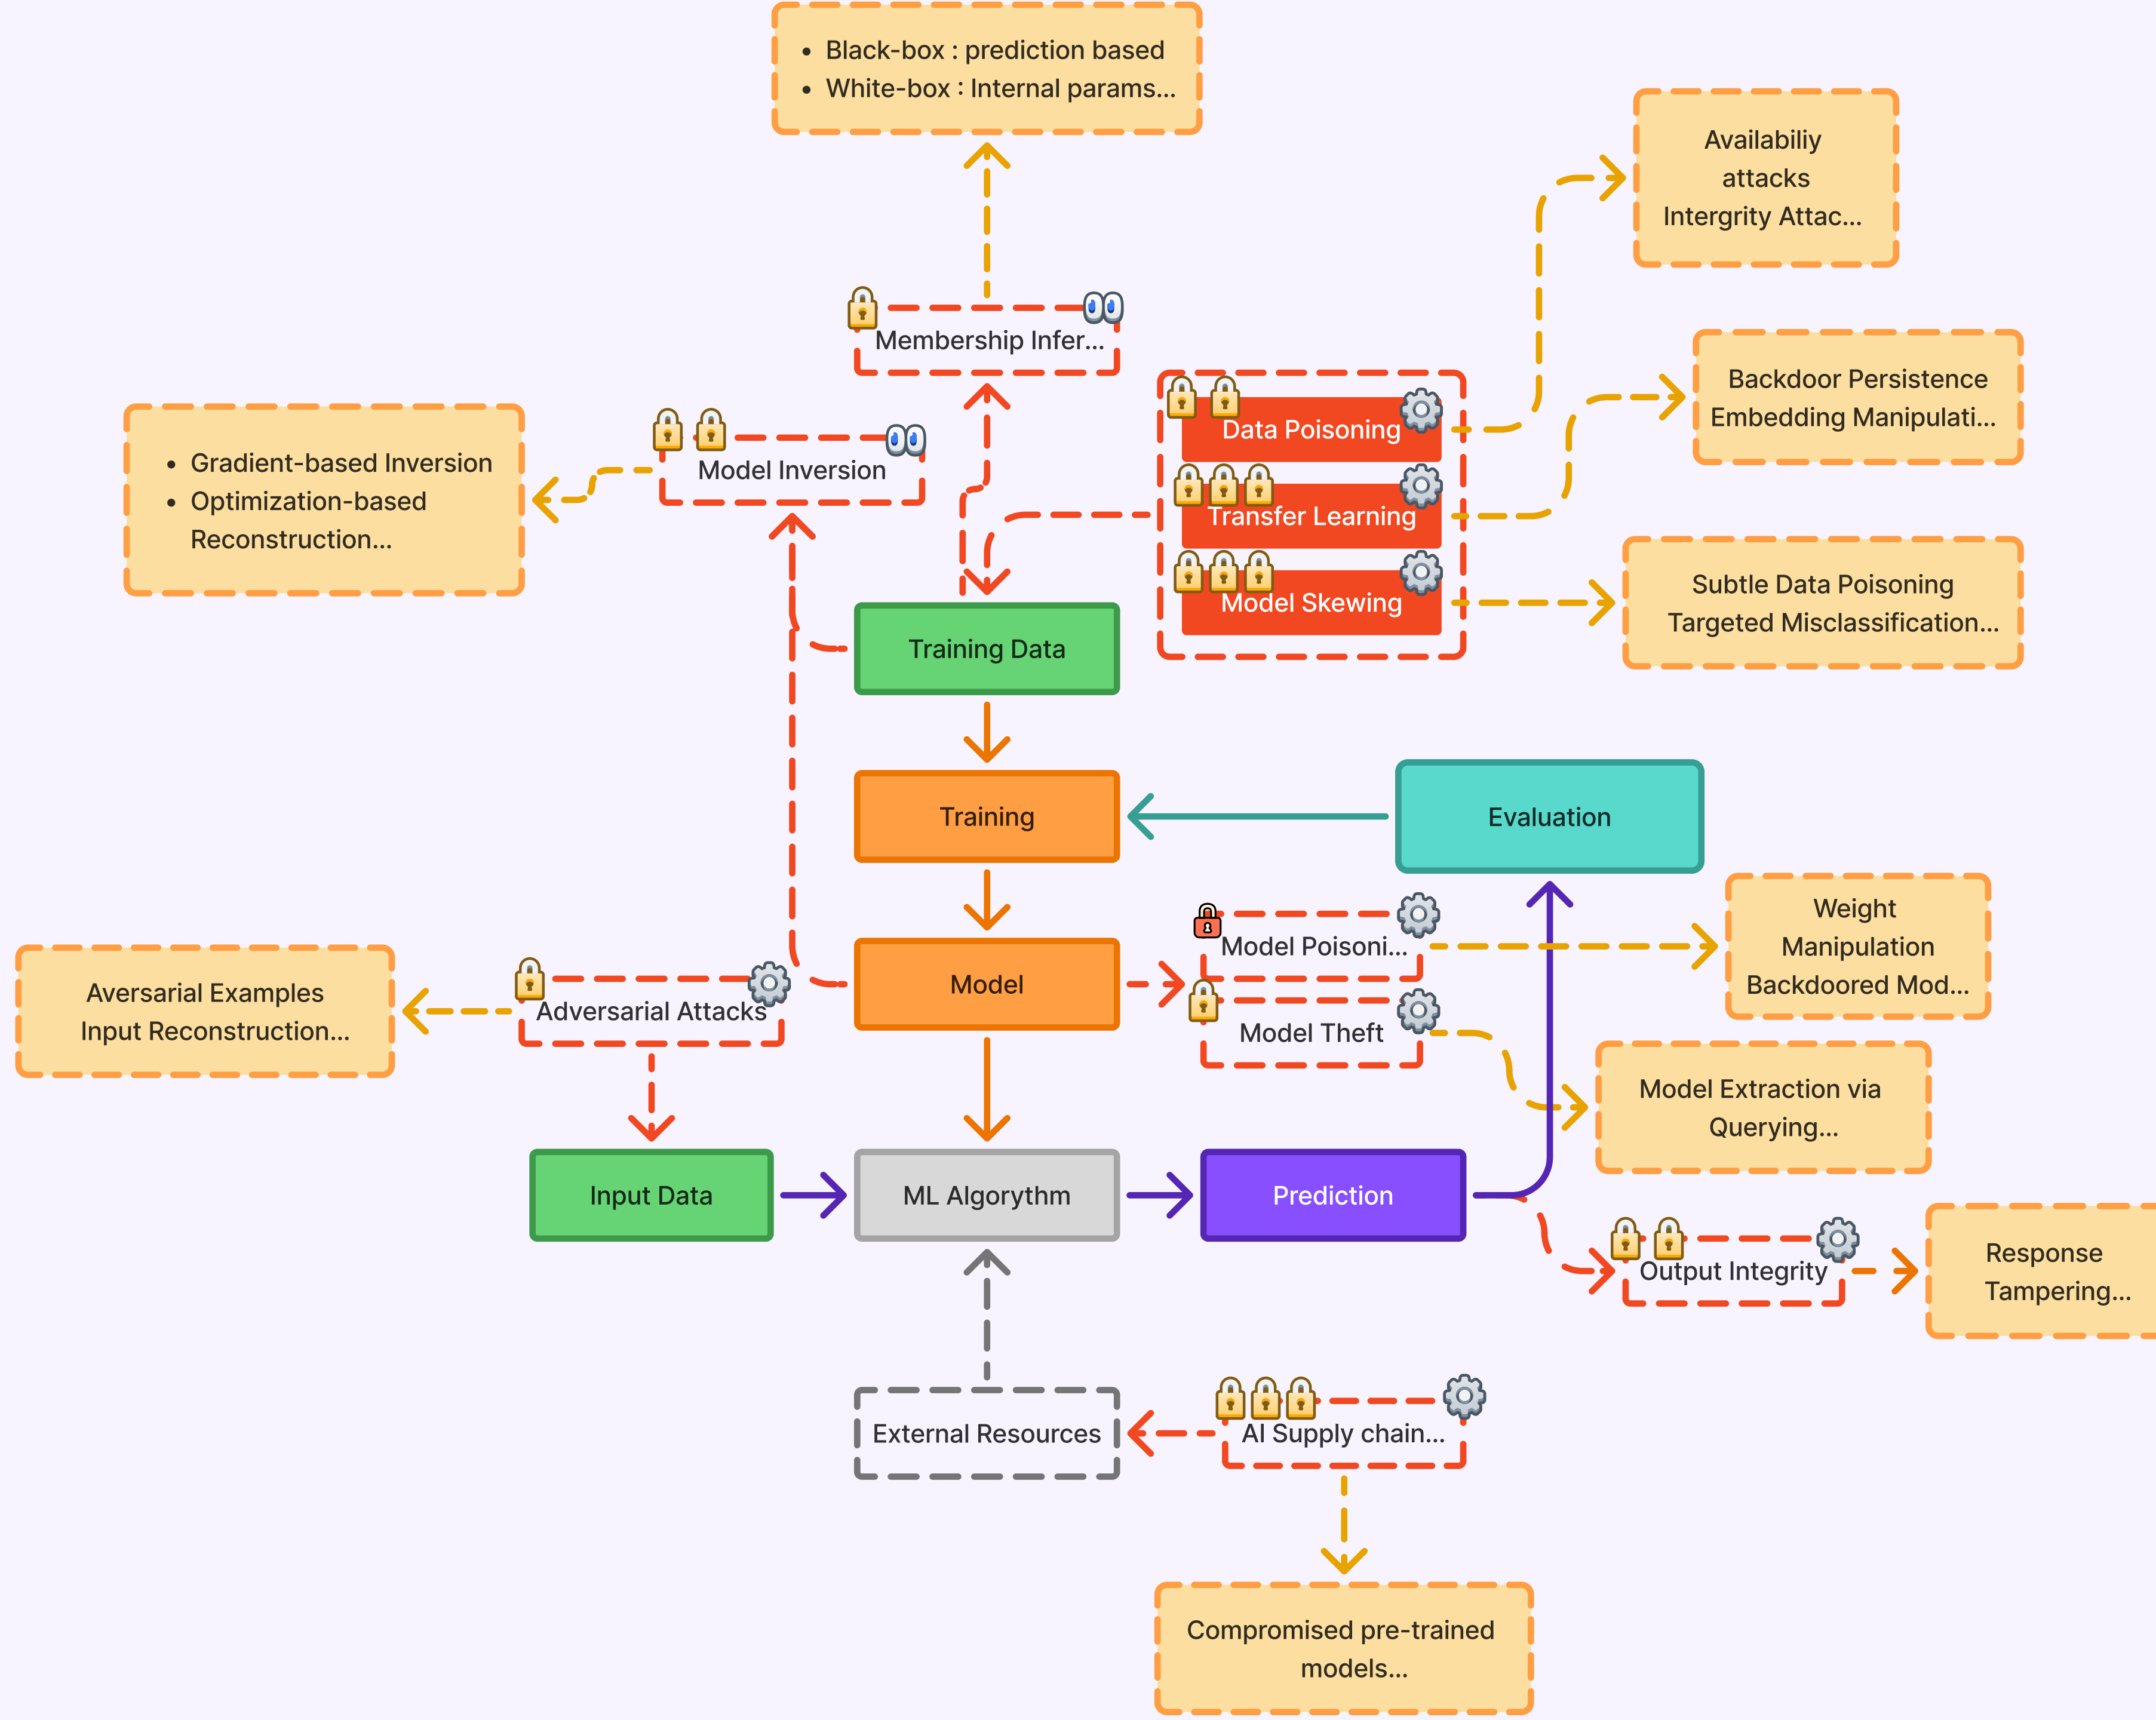
Sécurité

Cible des attaques

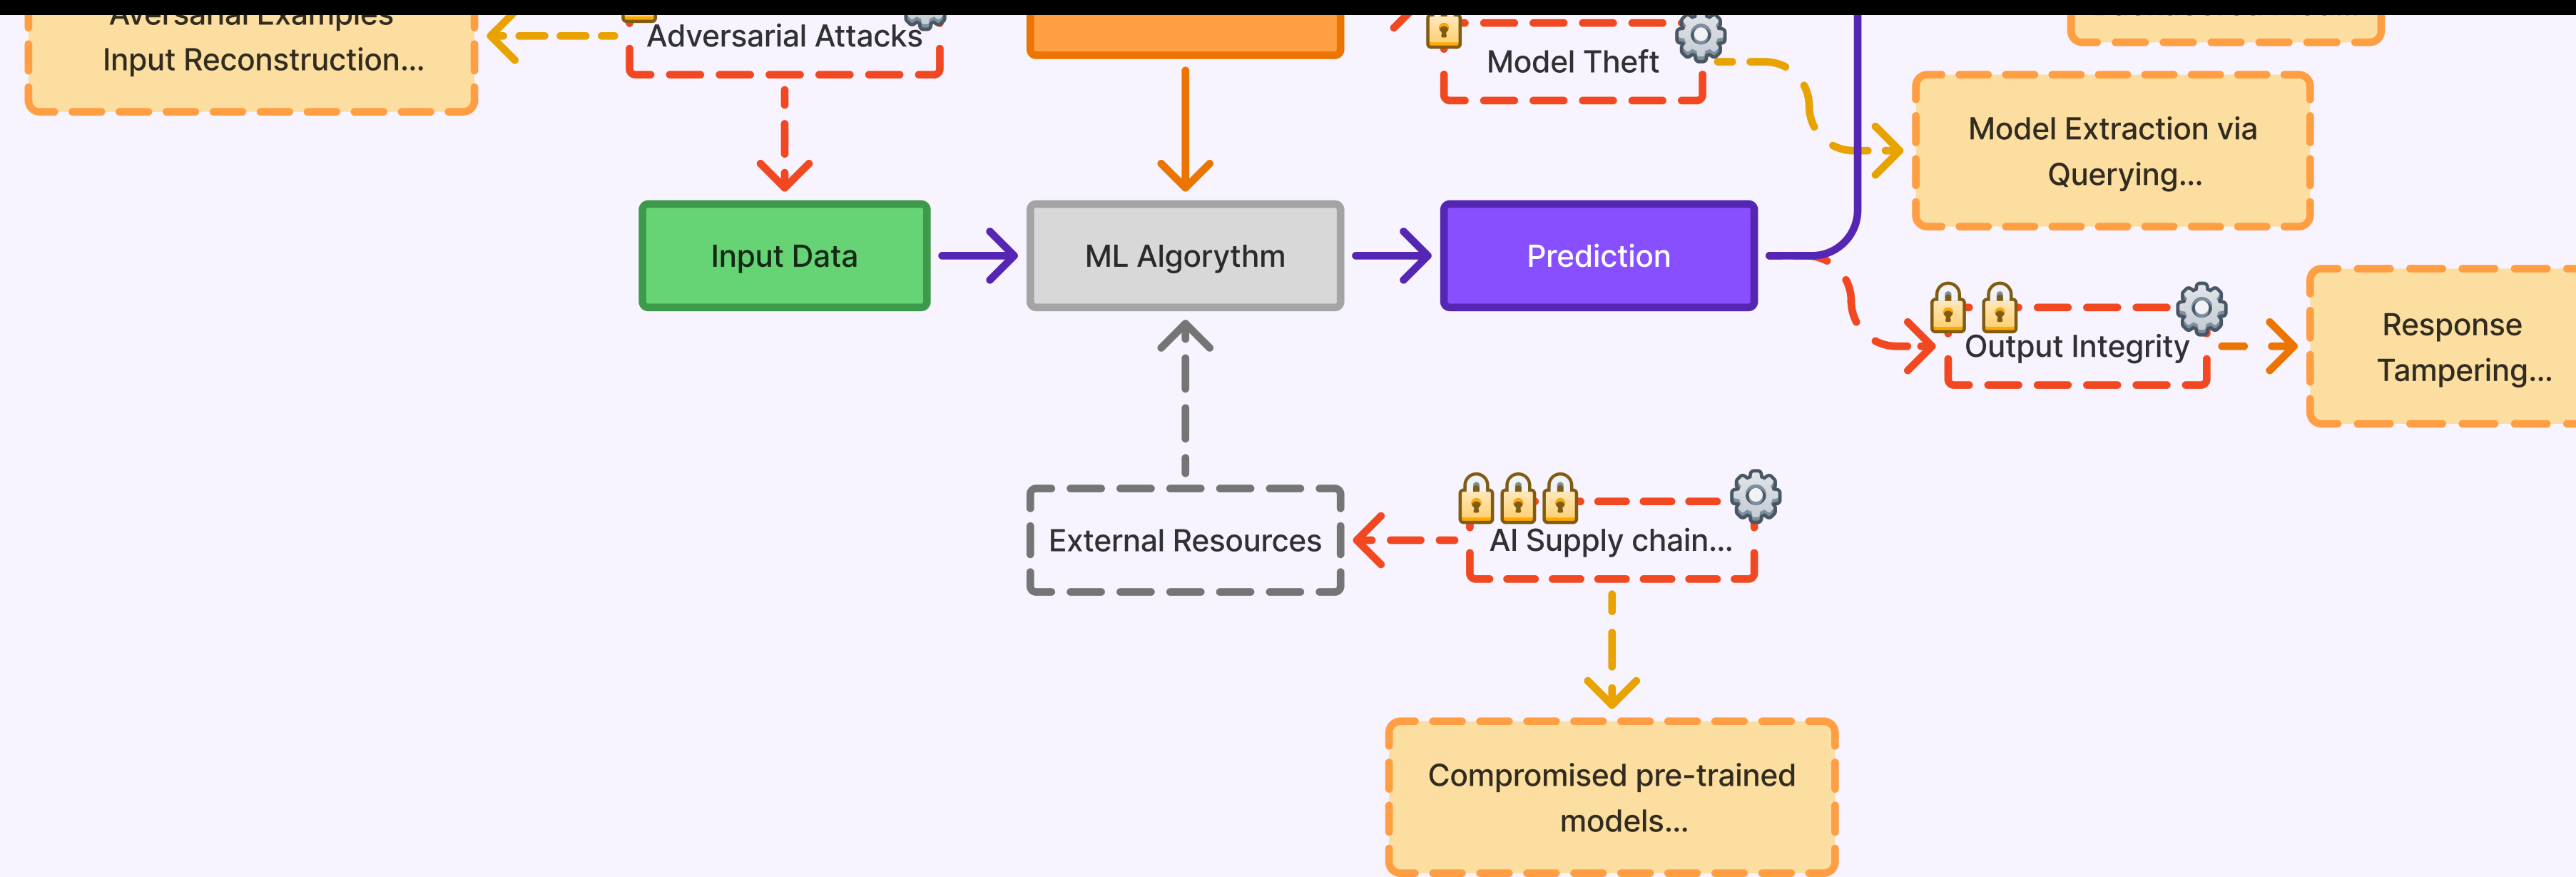

1

Données

Vecteur



Beaucoup d'attaques différentes...



03 - Objectif des recherches et problématique

“Sécurisation Des Systèmes D'apprentissage Automatique : Analyse Des Menaces Et Mécanismes De Défense”

OBJECTIFS D'APRÈS LE SUJET

Prévention, Détection, Défense

- Méthodes pour prévenir les menaces
- Méthodes pour détecter si possible
- Si détection alors appliquer des méthodes de défense

SYNTHÈSE DES OBJECTIFS

- Chercher des moyens de **détection** applicables à un **maximum** d'attaques différentes.
- Si une **attaque** est **détectée**, alors déterminer le type pour mettre en œuvre une **protection adaptée**
- Si la **détection échoue**, tout repose alors sur des techniques de **prévention**. Les enjeux ?
 - Réduction de l'impact des attaques
 - Moins d'altération possible des données

04 - Enjeux et difficultés

Enjeux

- **Modèle robuste**
- **Ne pas perdre d'information**
- **Faire attention au coût temporel et aux ressources**

→ **Faire un compromis entre ces trois points pour trouver une solution de sécurité optimale.**

Difficultés du sujet

- Nécessite une bonne **compréhension/documentation** sur le **sujet**
 - Pour comprendre le **fonctionnement**
 - Mettre en œuvre des **tests** dans des environnements cadrés
 - Pouvoir réfléchir à des **solutions**
- Sujet informatique d'actualité et innovant, mais sans garantie de **résultats**
- Pas d'**objectif à atteindre**, juste un **problème** à essayer de mieux comprendre en vue de **solutions**


05 - Résultats et analyse

ETUDE DE CAS

- Un centre de recherche médical utilise du Machine Learning pour la détection de la maladie d'Alzheimer
- Modèle entraîné pour rendre 4 prédictions :
 - CN (Cognitively Normal) → Aucun trouble
 - EMCI (Early Mild Cognitive Impairment) → Troubles précoces
 - LMCI (Late Mild Cognitive Impairment) → Troubles tardifs
 - AD (Alzheimer's Disease) → Maladie d'Alzheimer
- Basé sur des Images IRM (Imagerie par Résonance Magnétique)
- Images d'entraînement récupérées sur le site de l'ADNI (Alzheimer's Disease Neuroimaging Initiative)

EXEMPLE D'IMAGES

PRED - CN



PRED - AD



SOURCE : SITE DE L'ADNI


ETUDE DE CAS

- Un centre de recherche médical utilise du Machine Learning pour la détection de la maladie d'Alzheimer
- Modèle entraîné pour rendre 4 prédictions :
 - CN (Cognitively Normal) → Aucun trouble
 - EMCI (Early Mild Cognitive Impairment) → Troubles précoces
 - LMCI (Late Mild Cognitive Impairment) → Troubles tardifs
 - AD (Alzheimer's Disease) → Maladie d'Alzheimer
- Basé sur des Images IRM (Imagerie par Résonance Magnétique)
- Images d'entraînement récupérées sur le site de l'ADNI (Alzheimer's Disease Neuroimaging Initiative)


Précision de prédiction : 87.45%

EXEMPLE D'IMAGES

PRED - CN



PRED - AD



SOURCE : SITE DE L'ADNI

Un laboratoire concurrent souhaite nuire

Il engage des pirates informatique pour perturber leurs résultats

Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.

Un laboratoire concurrent souhaite nuire

Il engage des pirates informatique pour perturber leurs résultats

Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.

Notre laboratoire entraine donc son modèle sur des images corrompues

Sans le savoir ni une quelconque faille interne, 10% des images d'entraînement du laboratoire sont polluées

Principe de l'attaque

Un laboratoire concurrent souhaite nuire

Il engage des pirates informatique pour perturber leurs résultats

Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.

Notre laboratoire entraine donc son modèle sur des images corrompues

Sans le savoir ni une quelconque faille interne, 10% des images d'entraînement du laboratoire sont polluées

Un laboratoire concurrent souhaite nuire

Il engage des pirates informatique pour perturber leurs résultats


Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.

Notre laboratoire entraine donc son modèle sur des images corrompues

Sans le savoir ni une quelconque faille interne, 10% des images d'entraînement du laboratoire sont polluées

Principe de l'attaque



Un 3 manuscrit

Un laboratoire concurrent souhaite nuire

Il engage des pirates informatique pour perturber leurs résultats


Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.

Notre laboratoire entraine donc son modèle sur des images corrompues

Sans le savoir ni une quelconque faille interne, 10% des images d'entraînement du laboratoire sont polluées

Principe de l'attaque



Un 3 manuscrit

Un laboratoire concurrent souhaite nuire

Il engage des pirates informatique pour perturber leurs résultats


Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.

Notre laboratoire entraine donc son modèle sur des images corrompues

Sans le savoir ni une quelconque faille interne, 10% des images d'entraînement du laboratoire sont polluées

Principe de l'attaque



Un laboratoire concurrent souhaite nuire


Il engage des pirates informatique pour perturber leurs résultats

Les pirates introduisent des images altérées subtilement

Ils utilisent une faille sur le site de l'ADNI pour introduire des images modifiées.


Notre laboratoire entraine donc son modèle sur des images corrompues

Sans le savoir ni une quelconque faille interne, 10% des images d'entraînement du laboratoire sont polluées




Impact sur notre laboratoire de recherche

87.45%



Impact sur notre laboratoire de recherche



87.45%

-22.44%

Type attaque A


Précision de 65.01%

-25.13%


Type attaque B

Précision de 62.32%

En prévention : On met du bruit sur le bruit !



En prévention : On met du bruit sur le bruit !



En prévention : On met du bruit sur le bruit !

Mais pas n'importe comment

1

Déterminer le bruit

On calcule un indice de bruit présent sur l'image

2

Adapter proportionnellement

- Si une image a beaucoup de bruit, il faut en ajouter peu
- Si une image en a peu, il faut en ajouter suffisamment pour rééquilibrer

3

Moyens

On utilise des filtres pour calculer un "indice de bruit". Ensuite, selon le seuil, on ajoute du bruit

4

Résultat

Les images empoisonnées ont moins d'impact

id_code ∇	diagnosis ∇	label ∇	noise_level_before ∇	noise_level_after ∇	message_size ∇	message ∇
104	EMCI	ras	8016.419806480408	10067.180965598673	2000	fkq_-eGR^=wnWn(.aJGiC00(_YR-IzCu
105	LMCI	atk	12446.069078680128	12438.368347581476	500	65\a74^"QwCB(hktlR^`P7?X>D:8!4*c
106	EMCI	atk	12909.351659238338	12903.19330644235	500	-oVnvG9d11L4,>Yo^L7}D_z_M(=DzzYM
107	LMCI	ras	8173.999100740999	9896.92943070829	2000	Bp?k4-9/aW.9obdr9dm2]'6at8i8F9UI
108	LMCI	ras	9128.74152475223	10542.488338887691	2000	4>EY()J:8=o0E">..hEfTr)McCY"BZLT
109	AD	ras	7659.599074780941	9517.845731496811	2000	^}w*5mk1C=Y)9iP<k@nNXS"Aa%}s)x4]
110	LMCI	ras	8041.2469200491905	10076.423964794725	2000	da@rwn)n3'Ydpt7"3LuV5/SP,*\\//A+
111	EMCI	ras	7572.495019674301	9671.597144659609	2000	zj;Uvj/B6<BjMR[*`M)mfxFv{iIsZ"Ct
112	CN	ras	8560.931487083435	10064.97299861908	2000	MARjs'v^-fY7Be8g)~7h0XlUNhfE-xiV
113	CN	ras	7671.271078463644	9670.895660340786	2000	Nb7=\$vZtnQU3WHmckm\$>;Ss\YRl4% QC
114	LMCI	ras	7347.269456591457	9382.504920005798	2000	jw?#e@\$kq!7-R47K--uvsD[5:g-!)p=u
115	CN	ras	8249.520738363266	10064.538684543222	2000	\$)j2d+2=(Y*1;%kVU9"=?7W+8z,Fdm{g
116	AD	ras	7604.156861886382	10024.641112327576	2000	;7+!26?a*K*o:9w.PQo^s0w'VWmfPs?h
117	CN	ras	7533.012202914804	9701.529462754726	2000	%g2}Z\$\hA/p,S#"&@-e;0y)D#pH08d)6
118	AD	ras	8045.465822562575	9977.281834002584	2000	A7jcP][)n?),^{jc6]3)S.g\ -u%- 'yb!

Label

Indice de bruit

id_code ∇	÷	diagnosis ∇	÷	label ∇	÷	noise_level_before ∇	÷	noise_level_after ∇	÷	message_size ∇	÷	message ∇
104		EMCI		ras		8016.419806480408		10067.180965598673		2000		fkq_-eGR^=wnWn(.aJGiC00(_YR-IzCu
105		LMCI		atk		12446.069078680128		12438.368347581476		500		65\a74^"QwCB(hktlR^`P7?X>D:8!4*c
106		EMCI		atk		12909.351659238338		12903.19330644235		500		-oVnvG9d11L4,>Yo^L7}D_z_M(=DzzYM
107		LMCI		ras		8173.999100740999		9896.92943070829		2000		Bp?k4-9/aW.9obdr9dm2]'6at8i8F9UI
108		LMCI		ras		9128.74152475223		10542.488338887691		2000		4>EY()J:8=o0E">..hEfTr)McCY"BZlT
109		AD		ras		7659.599074780941		9517.845731496811		2000		^}w*5mk1C=Y)9iP<k@nNXS"Aa%}s)x4]
110		LMCI		ras		8041.2469200491905		10076.423964794725		2000		da@rwn)n3'Ydpt7"3LuV5/SP,*\\//A+
111		EMCI		ras		7572.495019674301		9671.597144659609		2000		zj;Uvj/B6<BjMR[*`M)mfxFv{iIsZ"Ct
112		CN		ras		8560.931487083435		10064.97299861908		2000		MARjs'v^-fY7Be8g)~7h0XlUNhfE-xiV
113		CN		ras		7671.271078463644		9670.895660340786		2000		Nb7=\$vZtnQU3WHmckm\$>;Ss\YRl4% QC
114		LMCI		ras		7347.269456591457		9382.504920005798		2000		jw?#e@\$kq!7-R47K--uvsD[5:g-!)p=u
115		CN		ras		8249.520738363266		10064.538684543222		2000		\$)j2d+2=(Y*1;%kVU9"=?7W+8z,Fdm{g
116		AD		ras		7604.156861886382		10024.641112327576		2000		;7+!26?a*K*o:9w.PQo^s0w'VWmfPs?h
117		CN		ras		7533.012202914804		9701.529462754726		2000		%g2}Z\$\hA/p,S#"&@-e;0y)D#pH08d)6
118		AD		ras		8045.465822562575		9977.281834002584		2000		A7jcP][)n?),^{jc6]3)S.g\ -u%- 'yb!

Label

Indice de bruit

id_code ∇	diagnosis ∇	label ∇	noise_level_before ∇	noise_level_after ∇	message_size ∇	message ∇
104	EMCI	ras	8016.419806480408	10067.180965598673	2000	fkq_-eGR^=wnWn(.aJGiC00(_YR-IzCu
105	LMCI	atk	12446.069078680128	12438.368347581476	500	65\ a74^"QwCB(hktlR^`P7?X>D:8!4*c
106	EMCI	atk	12909.351659238338	12903.19330644235	500	oVnvG9d11L4,>Yo^L7}D_z_M(=DzzYM
107	LMCI	ras	8173.999100740999	9896.92943070829	2000	Bp?k4-9/aW.9obdr9dm2]'6at8i8F9UI
108	LMCI	ras	9128.74152475223	10542.488338887691	2000	4>EY()J:8=o0E">..hEfTr)McCY"BZLT
109	AD	ras	7659.599074780941	9517.845731496811	2000	^}w*5mk1C=Y)9iP<k@nNXS"Aa%}s)x4]
110	LMCI	ras	8041.2469200491905	10076.423964794725	2000	da@rwn)n3'Ydpt7"3LuV5/SP,*\\//A+
111	EMCI	ras	7572.495019674301	9671.597144659609	2000	zj;Uvj/B6<BjMR[*`M)mfxFv{iIsZ"Ct
112	CN	ras	8560.931487083435	10064.97299861908	2000	MARjs'v^-fY7Be8g)~7h0XlUNhfE-xiV
113	CN	ras	7671.271078463644	9670.895660340786	2000	Nb7=\$vZtnQU3WHmckm\$>;Ss\YRl4% QC
114	LMCI	ras	7347.269456591457	9382.504920005798	2000	jw?#e@\$kq!7-R47K--uvsD[5:g-!)p=u
115	CN	ras	8249.520738363266	10064.538684543222	2000	\$)j2d+2=(Y*1;%kVU9"=?7W+8z,Fdm{g
116	AD	ras	7604.156861886382	10024.641112327576	2000	;7+!26?a*K*o:9w.PQo^s0w'VWmfPs?h
117	CN	ras	7533.012202914804	9701.529462754726	2000	%g2}Z\$\hA/p,S#"&@-e;0y)D#pH08d)6
118	AD	ras	8045.465822562575	9977.281834002584	2000	A7jcP][)n?),^{jc6]3)S.g\ -u%- 'yb!

Label

Indice de bruit

id_code ∇	diagnosis ∇	label ∇	noise_level_before ∇	noise_level_after ∇	message_size ∇	message ∇
104	EMCI	ras	8016.419806480408	10067.180965598673	2000	fkq_-eGR^=wnWn(.aJGiC00(_YR-IzCu
105	LMCI	atk	12446.069078680128	12438.368347581476	500	65\ a74^"QwCB(hktlR^`P7?X>D:8!4*c
106	EMCI	atk	12909.351659238338	12903.19330644235	500	oVnvG9d11L4,>Yo^L7}D_z_M(=DzzYM
107	LMCI	ras	8173.999100740999	9896.92943070829	2000	Bp?k4-9/aW.9obdr9dm2]'6at8i8F9UI
108	LMCI	ras	9128.74152475223	10542.488338887691	2000	4>EY()J:8=o0E">..hEfTr)McCY"BZLT
109	AD	ras	7659.599074780941	9517.845731496811	2000	^}w*5mk1C=Y)9iP<k@nNXS"Aa%}s)x4]
110	LMCI	ras	8041.2469200491905	10076.423964794725	2000	da@rwn)n3'Ydpt7"3LuV5/SP,*\\//A+
111	EMCI	ras	7572.495019674301	9671.597144659609	2000	zj;Uvj/B6<BjMR[*`M)mfxFv{iIsZ"Ct
112	CN	ras	8560.931487083435	10064.97299861908	2000	MARjs'v^-fY7Be8g)~7h0XlUNhfE-xiV
113	CN	ras	7671.271078463644	9670.895660340786	2000	Nb7=\$vZtnQU3WHmckm\$>;Ss\YRl4% QC
114	LMCI	ras	7347.269456591457	9382.504920005798	2000	jw?#e@\$kq!7-R47K--uvsD[5:g-!)p=u
115	CN	ras	8249.520738363266	10064.538684543222	2000	\$)j2d+2=(Y*1;%kVU9"=?7W+8z,Fdm{g
116	AD	ras	7604.156861886382	10024.641112327576	2000	;7+!26?a*K*o:9w.PQo^s0w'VWmfPs?h
117	CN	ras	7533.012202914804	9701.529462754726	2000	%g2}Z\$\hA/p,S#"&@-e;0y)D#pH08d)6
118	AD	ras	8045.465822562575	9977.281834002584	2000	A7jcP][)n?),^{jc6]3)S.g\ -u%- 'yb!

Label


> 12000

Indice de bruit


id_code ∇	diagnosis ∇	label ∇	noise_level_before ∇	noise_level_after ∇	message_size ∇	message ∇
104	EMCI	ras	8016.419806480408	10067.180965598673	2000	fkq_-eGR^=wnWn(.aJGiC00(_YR-IzCu
105	LMCI	atk	12446.069078680128	12438.368347581476	500	65\a74^"QwCB(hktlR^`P7?X>D:8!4*c
106	EMCI	atk	12909.351659238338	12903.19330644235	500	-oVnvG9d11L4,>Yo^L7}D_z_M(=DzzYM
107	LMCI	ras	8173.999100740999	9896.92943070829	2000	8p?k4-9/aW.9obdr9dm2]'6at8i8F9UI
108	LMCI	ras	9128.74152475223	10542.488338887691	2000	4>EY()J:8=o0E">..hEfTr)McCY"BZLT
109	AD	ras	7659.599074780941	9517.845731496811	2000	^}w*5mk1C=Y)9iP<k@nNXS"Aa%}s)x4]
110	LMCI	ras	8041.2469200491905	10076.423964794725	2000	0a@rwn)n3'Ydpt7""3LuV5/SP,*\\//A+
111	EMCI	ras	7572.495019674301	9671.597144659609	2000	zj;Uvj/B6<BjMR[*`M)mfxFv{iIsZ"Ct
112	CN	ras	8560.931487083435	10064.97299861908	2000	MARjs'v^-fY7Be8g)~7h0XlUNhfE-xiV
113	CN	ras	7671.271078463644	9670.895660340786	2000	Wb7=\$vZtnQU3WHmckm\$>;Ss\YRl4% QC
114	LMCI	ras	7347.269456591457	9382.504920005798	2000	jw?#e@\$kq!7-R47K--uvsD[5:g-!)p=u
115	CN	ras	8249.520738363266	10064.538684543222	2000	\$)j2d+2=(Y*1;%kVU9"=?7W+8z,Fdm{g
116	AD	ras	7604.156861886382	10024.641112327576	2000	7+!26?a*K*o:9w.PQo^s0w'VWmfPs?h
117	CN	ras	7533.012202914804	9701.529462754726	2000	%g2}Z\$\hA/p,S#"&@-e;0y)D#pH08d)6
118	AD	ras	8045.465822562575	9977.281834002584	2000	A7jcP][)n?),^{jc6]3)S.g\~u%- 'yb!


Label


< 12000
> 7500



id_code ∇	diagnosis ∇	label ∇	noise_level_before ∇	noise_level_after ∇	message_size ∇	message ∇
104	EMCI	ras	8016.419806480408	10067.180965598673	2000	fkq_-eGR^=wnWn(.aJGiC00(_YR-IzCu
105	LMCI	atk	12446.069078680128	12438.368347581476	500	5\ a74^"QwCB(hktlR^`P7?X>D:8!4*c
106	EMCI	atk	12909.351659238338	12903.19330644235	500	-oVnvG9d11L4,>Yo^L7}D_z_M(=DzzYf
107	LMCI	ras	8173.999100740999	9896.92943070829	2000	Bp?k4-9/aW.9obdr9dm2]'6at8i8F9UI
108	LMCI	ras	9128.74152475223	10542.488338887691	2000	>EY()J:8=o0E">..hEfTr)McCY"BZLT
109	AD	ras	7659.599074780941	9517.845731496811	2000	^}w*5mk1C=Y)9iP<k@nNXS"Aa%}s)x4]
110	LMCI	ras	8041.2469200491905	10076.423964794725	2000	da@rwn)n3'Ydpt7""3LuV5/SP,*\\//A+
111	EMCI	ras	7572.495019674301	9671.597144659609	2000	zj;Uvj/B6<BjMR[*`M)mfxFv{iIsZ"Ct
112	CN	ras	8560.931487083435	10064.97299861908	2000	MARjs'v^-fY7Be8g)~7h0XlUNhfE-xiV
113	CN	ras	7671.271078463644	9670.895660340786	2000	Nb7=\$vZtnQU3WHmckm\$>;Ss\YRl4% QC
114	LMCI	ras	7347.269456591457	9382.504920005798	2000	jw?#e@\$kq!7-R47K--uvsD[5:g-!)p=u
115	CN	ras	8249.520738363266	10064.538684543222	2000	\$)j2d+2=(Y*1;%kVU9"=?7W+8z,Fdm{g
116	AD	ras	7604.156861886382	10024.641112327576	2000	;7+!26?a*K*o:9w.PQo^s0w'VWmfPs?h
117	CN	ras	7533.012202914804	9701.529462754726	2000	%g2}Z\$\hA/p,S#"&@-e;0y)D#pH08d)6
118	AD	ras	8045.465822562575	9977.281834002584	2000	A7jcP][)n?),^{jc6]3)S.g\ -u%- 'yb!









Dataset attaqué

Même dataset
+ ajout de bruit





Continuité - Données moins “standardisées”




Image	Attacked	Original Class	Original Confidence	Attacked Class	Attacked Confidence	Attack Success	Confidence Change
road0.png	Yes	trafficlight	0.2625	stop	0.2524	Yes	-0.0100
road1.png	Yes	trafficlight	0.2573	trafficlight	0.2549	No	-0.0024
road10.png	Yes	trafficlight	0.2629	trafficlight	0.2517	No	-0.0112
road100.png	Yes	speedlimit	0.2727	stop	0.2532	Yes	-0.0195
road101.png	Yes	speedlimit	0.2693	stop	0.2546	Yes	-0.0146
road102.png	Yes	speedlimit	0.2654	stop	0.2559	Yes	-0.0095
road103.png	Yes	speedlimit	0.2725	stop	0.2554	Yes	-0.0171
road104.png	Yes	speedlimit	0.2659	speedlimit	0.2566	No	-0.0093
road105.png	Yes	speedlimit	0.2700	speedlimit	0.2563	No	-0.0137
road106.png	Yes	speedlimit	0.2627	stop	0.2534	Yes	-0.0093
road107.png	Yes	speedlimit	0.2644	stop	0.2554	Yes	-0.0090
road108.png	Yes	speedlimit	0.2568	trafficlight	0.2520	Yes	-0.0049
road109.png	Yes	speedlimit	0.2620	stop	0.2534	Yes	-0.0085
road11.png	Yes	crosswalk	0.2549	trafficlight	0.2549	Yes	0.0000
road110.png	Yes	speedlimit	0.2688	speedlimit	0.2537	No	-0.0151
road111.png	Yes	speedlimit	0.2617	stop	0.2534	Yes	-0.0083
road112.png	Yes	speedlimit	0.2700	speedlimit	0.2539	No	-0.0161

06 - Analyse du stage

Ce que je changerais :

Choix de l'algorithme

Moins de perte de temps sur l'analyse de la pertinence des différents algorithmes - utilisation directe des algorithmes réputés les plus pertinents

Concentration sur un aspect

Me concentrer directement sur un type d'attaque spécifique pour éviter de simplement faire une taxonomie des différentes attaques

Documentation plus ciblée

Ce qui me permettrait d'être plus efficace sur ma documentation et perdre moins de temps (8 semaines passent déjà vite)

Apport en terme de compétences :

En terme d'Apprentissage Automatique

- Développement et entraînement de modèles
- Utilisation de bibliothèques et frameworks réputés
- Protection de modèles IA

Compétences Analytiques

- Prétraitement et analyse de données
- Résolution de problèmes

Documentation et communication

- Rédaction de rapports
- Elaboration de schémas
- Expliquer des concepts complexes de manière moins complexe
- Echanger en équipe autour de solutions

07 - Conclusion

Le travail effectué durant ce stage permet de :

- Laisser une documentation sur les différentes attaques, leur niveau d'action etc...
- Créer une base d'environnement de test d'attaques
- Proposer des concepts de solutions pouvant être affinées et appliquées à plus grande échelle
- Permettre de mieux appréhender les possibilités de sécurisation en Machine Learning
- Proposer un principe de prévention et d'atténuation

Merci pour votre attention !

Quelles sont vos questions

